



基础数理统计

(研究生公共课)

肖柳青 教授 博士主讲



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

第 2 章 参数估计 (Parametric Estimation)



主要内容

1. 点估计的基本概念
2. 两种基本的点估计方法
3. 点估计的优良标准 (无偏性及有效估计和C-R下界)
4. 最佳点估计 (充分统计量)
5. 置信区间估计
6. 贝叶斯估计

参数估计的原理



设总体 X 的分布函数的形式已知，但含有一个或多个未知参数： $\theta_1, \theta_2, \dots, \theta_k$

参数是刻画总体某方面概率特性的数量。

设 X_1, X_2, \dots, X_n 为总体的一组样本，如何构造 k 个统计量：

$$\left. \begin{array}{l} \theta_1(X_1, X_2, \dots, X_n) \\ \theta_2(X_1, X_2, \dots, X_n) \\ \dots\dots\dots \\ \theta_k(X_1, X_2, \dots, X_n) \end{array} \right\}$$

随机变量！

分布中参数的重要性



参数估计就是当参数未知时, 从总体抽出一个子样, 用某种方法对这个未知参数进行估计.

例如, $X \sim N(\mu, \sigma^2)$,

若 μ, σ^2 未知, 通过构造样本的函数, 给出它们的估计值或取值范围就是参数估计的内容.

点估计

区间估计

参数估计的类型



点估计 —— 估计未知参数的值

区间估计 —— 即求置信区间：

估计未知参数的取值范围，
并使此范围包含未知参数
真值的概率为给定的值。

1. 点估计的基本概念 (Point Estimator)

点估计： 由样本 X_1, X_2, \dots, X_n 确定一个统计量

$$\hat{\theta} = g(X_1, X_2, \dots, X_n)$$

用它估计总体的未知参数，称为总体参数的估计量。

当具体的样本抽出后，可求得出样本统计量的值。用它作为总体参数的估计值，称作总体参数的点估计值。

2. 几种基本的点估计方法



- 矩估计 (Moment Estimate)
- 极大似然估计 (Maximum Likelihood Estimate)
 - 多项分布的极大似然估计
 - 极大似然估计的渐进分布
 - 极大似然估计的置信区间解法
- 最小二乘法
- 贝叶斯方法
-

(1) 矩估计法

它是基于一种简单的“**替换**”思想建立起来的一种估计方法。



是英国统计学家**K.皮尔逊**最早提出的。

其基本思想是**用样本矩估计总体矩**。

理论依据：辛钦大数定律

矩估计法具体做法:

设 X 是一随机变量, X_1, X_2, \dots, X_n 是它的一个样本。

若 $E(X^k)$ 存在, 则称之为 X 的 k 阶原点矩。记作 V_k

若 $E[(X - E(X))^k]$ 存在, 则称之为 X 的 k 阶中心矩。记作 U_k

称 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 为样本的 k 阶原点矩。

称 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ 为样本的 k 阶中心矩。

$$\text{矩法估计: } \hat{V}_k = A_k, \quad \hat{U}_k = B_k$$

这是包含 k 个未知参数 $\theta_1, \dots, \theta_k$ 的联立方程组,

$$\begin{cases} A_1 = \mu_1(\theta_1, \theta_2, \dots, \theta_k) \\ A_2 = \mu_2(\theta_1, \theta_2, \dots, \theta_k) \\ \dots \dots \dots \dots \\ A_k = \mu_k(\theta_1, \theta_2, \dots, \theta_k) \end{cases}$$


$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k,$$

从中解出方程组的解,记为 $\hat{\theta}_1, \dots, \hat{\theta}_k$,即

$$\begin{cases} \hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n) \\ \hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n) \\ \dots \dots \dots \dots \\ \hat{\theta}_k = \hat{\theta}_k(X_1, X_2, \dots, X_n) \end{cases}$$

矩估计法

矩估计法
实际上转化成
解非线性方程组



例1 设总体 X 的概率密度为

$$f(x) = \begin{cases} (\alpha + 1)x^\alpha, & 0 < x < 1 \\ 0, & \text{其它} \end{cases}$$

其中 $\alpha > -1$
是未知参数,

X_1, X_2, \dots, X_n 是取自 X 的样本, 求参数 α 的矩估计.

数学期望
是一阶
原点矩

解: $\mu_1 = E(X) = \int_0^1 x(\alpha + 1)x^\alpha dx$

$$= (\alpha + 1) \int_0^1 x^{\alpha+1} dx = \frac{\alpha + 1}{\alpha + 2}$$

由矩法,

$$\bar{X} = \frac{\alpha + 1}{\alpha + 2}$$

总体矩

样本矩

从中解得 $\hat{\alpha} = \frac{2\bar{X} - 1}{1 - \bar{X}}$, 即为 α 的矩估计.

矩法的优点是简单易行,并不需要事先知道总体是什么分布.

缺点是,当总体类型已知时,没有充分利用分布提供的信息.一般场合下,矩估计量不具有唯一性.

其主要原因在于建立矩法方程时,选取那些总体矩用相应样本矩代替带有一定的随意性.

矩估计量不是唯一的例子你能举出吗?



2. 极大似然法

MLE

是在总体类型已知条件下使用的一种参数估计方法。

它首先是由德国数学家高斯在1821年提出的，然而，这个方法常归功于英国统计学家费歇。

费歇在1922年重新发现了这一方法，并首先研究了这种方法的一些性质。



极大似然法的原理

先看一个简单例子：
某位同学与一位猎人一起外出打猎。

一只野兔从前方窜过。
只听一声枪响，野兔应声倒下。



如果要你推测，
是谁打中的呢？
你会如何想呢？



你就会想，只发一枪便打中，猎人命中的概率一般大于这位同学命中的概率。看来这一枪是猎人射中的。

这个例子所作的推断已经体现了极大似然法的基本思想。

下面我们再看一个具体例子，进一步体会极大似然法的基本思想。



例2 设 $X \sim B(1, p)$, p 未知. 假设我们事先知道 p 只有两种可能:

$$p=0.7 \quad \text{或} \quad p=0.3$$

如今重复试验3次, 得结果: 0, 0, 0

问: 应如何估计 p ?

由概率论的知识, 3次试验中出现“1”的次数

$$Y \sim B(3, p)$$

$$P(Y = k) = \binom{3}{k} p^k (1-p)^{n-k} \quad k=0, 1, 2, 3$$

将估计结果

出现

出现

出现

出现

估计

p 值	$P(Y=0)$	$P(Y=1)$	$P(Y=2)$	$P(Y=3)$
0.7	0.027	0.189	0.441	0.343
0.3	0.343	0.441	0.189	0.027

估计

0.343

0.441

0.441

估计

0.343

应如何估计 p ?

$p=0.7$ 或 $p=0.3$

$$P(Y = k) = \binom{3}{k} p^k (1-p)^{3-k} \quad k=0,1,2,3$$

$P=0.7$, $p=0.3$
假设如何确认?
多种情况?
不是常数?



定义：设总体 X 的密度为 $f(x; \theta)$

(当 X 为离散型时 $f(x; \theta)$ 为分布列)，

$\theta = (\theta_1, \theta_2, \dots, \theta_l)$ 是总体的未知参数， x_1, x_2, \dots, x_n 是样本 X_1, X_2, \dots, X_n 的一组样本值，则称

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

① 求导麻烦!! 转向 $\ln L(\theta)$!!

为样本的**似然函数**。若存在某个 $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_l)$ ，使得 ②

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

成立(其中 Θ 为参数空间)，则称

即选取的估计量 $\hat{\theta}$ 应满足

$$\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n) = (\hat{\theta}_1(X_1, \dots, X_n), \hat{\theta}_2(X_1, \dots, X_n), \dots, \hat{\theta}_l(X_1, \dots, X_n)),$$

为 θ 的**极大似然估计量**。称

$$\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n) = (\hat{\theta}_1(x_1, \dots, x_n), \hat{\theta}_2(x_1, \dots, x_n), \dots, \hat{\theta}_l(x_1, \dots, x_n)),$$

为 θ 的**极大似然估计值**。③ 如何求？

$L(\theta)$ 是 θ 的函数，可用求导的方法找到使 $L(\theta)$ 达到最大值的 θ 。
注意到 $\ln L(\theta)$ 为单增函数，故 $L(\theta)$ 与 $\ln L(\theta)$ 达到最大值的自变量相同，故问题可转化为求 $\ln L(\theta)$ 的最大值点。

① 由总体分布建立似然函数 $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ —— 把自变量 x 看成常数, 把未知参数 $\theta = (\theta_1, \theta_2, \dots, \theta_l)$ 看成自变量;

② 求似然函数 $L(\theta)$ 的最大值点 —— 转化为求 $\ln L(\theta)$ 的最大值点,

即

1⁰ 建立似然方程组: $\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0 \quad (i=1, 2, \dots, l),$

2⁰ 解似然方程组得到 $L(\theta)$ 的最大值点;

③ 将样本 x_1, x_2, \dots, x_n 代入最大值点的表达式中, 就得未知参数的极大似然估计值 $\hat{\theta}$, 将样本值 x_1, x_2, \dots, x_n 代入最大值点的表达式中, 就得未知参数的极大似然估计值 $\hat{\theta}$.

✚ θ 是实数时, 似然方程组就是方程 $\frac{d \ln L(\theta)}{d \theta} = 0.$

下面举例说明如何求极大似然估计

MLE方法本质上是求最小值问题。大量经典解法是非线性方程组的求解



例4 设总体 $X \sim B(1, p)$,

其分布列为

$$f(x; p) = p^x (1-p)^{1-x}, \quad x = 0, 1$$

1, 0, 0, 1, 0, 0 是取自总体的一组样本值求参数 p 的极大似然估计.

解 样本的似然函数为: $L(p) = \prod_{i=1}^n P(x_i; p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}$

$$\begin{aligned} \text{对数似然函数为: } \ln L(p) &= \sum_{i=1}^n x_i \ln p + \sum_{i=1}^n (1-x_i) \ln (1-p) \\ &= \sum_{i=1}^n x_i \ln p + (n - \sum_{i=1}^n x_i) \ln (1-p) \end{aligned}$$

对 p 求导并令其为 0 得似然方程: $\frac{d \ln L(p)}{dp} = \frac{1}{p} \sum_{i=1}^n x_i - \frac{1}{1-p} (n - \sum_{i=1}^n x_i) = 0$,

解之得 p 的极大似然估计量: $\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$,

代入样本值即得极大似然估计值为: $\hat{p} = \frac{1}{6} (1+0+0+1+0+0) = \frac{1}{3}$.

例3 设总体 X 的密度为

$$f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x > 0; \\ 0, & \text{其它,} \end{cases}$$

其中 $\lambda > 0$ 为未知参数, X_1, X_2, \dots, X_n 是取自总体 X 的一组样本, 求 λ 的极大似然估计量与矩估计量.

解(1) 样本的似然函数为

$$L(\lambda) = \prod_{i=1}^n f(x_i; \lambda) = \begin{cases} \lambda^n \prod_{i=1}^n e^{-\lambda x_i}, & x_i > 0, i=1, 2, \dots, n; \\ 0, & \text{其他.} \end{cases}$$

当 $x_i > 0$ 时, $L(\lambda) > 0, 1 \leq i \leq n$,

故有对数似然函数: $\ln L(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i$,

对 λ 求导并令其为 0 可得似然方程: $\frac{d \ln L(\lambda)}{d \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$,

解得 极大似然估计量: $\hat{\lambda} = n / \sum_{i=1}^n X_i = \frac{1}{\bar{X}}$;

(2) $EX = \int_{-\infty}^{+\infty} x f(x; \lambda) dx = 1/\lambda$,

令 $\frac{1}{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$,

解得矩估计量: $\hat{\lambda} = \frac{1}{\bar{X}}$.

例5 设总体 X 服从均匀分布 $U[0, \theta]$, 为 θ 未知参数,
 X_1, X_2, \dots, X_n 是总体 X 的一组样本, 求 θ 的极大似然估计量.

解 样本的似然函数为

不必建立
对数似然方程

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \begin{cases} \frac{1}{\theta^n} & 0 \leq x_i \leq \theta, i=1, 2, \dots, n; \\ 0, & \text{其他.} \end{cases}$$

$$\frac{dL(\theta)}{d\theta} = -n\theta^{-(n+1)},$$

无法用求导建立似然方程的方法确定其极大似然估计量!!

用极大似然原则来求: 即用其他方法求似然函数 $L(\theta)$ 的最大值点.
显然, 似然函数 $L(\theta)$ 的值随 θ 的减小而增大, 故应取 θ 的值尽量地小;

另一方面, θ 必须满足条件 $0 \leq x_i \leq \theta$ ($i=1, 2, \dots, n$),
而事件 $\{0 \leq X_i \leq \theta, i=1, 2, \dots, n\} = \{\max_{1 \leq i \leq n} \{X_i\} \leq \theta\}$

故可取极大似然估计量为 $\hat{\theta} = \max_{1 \leq i \leq n} \{X_i\}$.

可证明极大似然估计具有下面的单调函数不变性:

若 $\hat{\theta}$ 为未知参数 θ 的极大似然估计量, 而 $g(\theta)$ 为 θ 的单调函数, 则 $g(\hat{\theta})$ 也是 $g(\theta)$ 的极大似然估计量.

[例] 一罐中装有白球和黑球, 有放回地抽取一个容量为 n 的样本, 其中有 k 个白球, 求罐中黑球与白球之比 R 的极大似然估计.

解 设 X_1, X_2, \dots, X_n 为所取样本, $X_i = \begin{cases} 1, & \text{取到白球} \\ 0, & \text{取到黑球} \end{cases} \quad i = 1, \dots, n$
则 $X_1, \dots, X_n \sim B(1, p)$, p 是每次抽取时取到白球的概率, 且 p 未知.

容易求得 p 的极大似然估计为: $\hat{p} = \frac{k}{n}$, $\therefore R = \frac{1-p}{p}$,

由极大似然估计的不变性知 R 的极大似然估计是 $\hat{R} = \frac{1-\hat{p}}{\hat{p}} = \frac{n}{k} - 1$.

✱ 上述解法是应用微积分中的技巧求似然函数 $L(\theta)$ 的最大值点. 但当似然函数 $L(\theta)$ 不可微或偏导数不为零时, 就不能用上述求导方法求未知参数的极大似然估计了. 这时要用极大似然原则来求.

[例] 设总体 X 服从均匀分布 $U[0, \theta]$, 为 θ 未知参数,

X_1, X_2, \dots, X_n 是总体 X 的一组样本, 求 θ 的极大似然估计量.

解 样本的似然函数为

不必建立
对数似然方程

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \begin{cases} \frac{1}{\theta^n} & 0 \leq x_i \leq \theta, i=1, 2, \dots, n; \\ 0, & \text{其他.} \end{cases}$$

$$\frac{dL(\theta)}{d\theta} = -n\theta^{-(n+1)},$$

无法用求导建立似然方程的方法确定其极大似然估计量!!

用极大似然原则来求: 即用其他方法求似然函数 $L(\theta)$ 的最大值点.

显然, 似然函数 $L(\theta)$ 的值随 θ 的减小而增大, 故应取 θ 的值尽量地小;

另一方面, θ 必须满足条件 $0 \leq x_i \leq \theta$ ($i=1, 2, \dots, n$),

而事件 $\{0 \leq X_i \leq \theta, i=1, 2, \dots, n\} = \{\max_{1 \leq i \leq n} \{X_i\} \leq \theta\}$

故可取极大似然估计量为 $\hat{\theta} = \max_{1 \leq i \leq n} \{X_i\}$.

[例] 设 X 的分布函数为

$$F(x; \alpha, \beta) = \begin{cases} 1 - (\frac{\alpha}{x})^\beta, & x > \alpha, \\ 0, & x \leq \alpha, \end{cases}$$

其中 $\alpha > 0, \beta > 1$, X_1, \dots, X_n 是总体 X 的样本, 求 $\alpha=1$ 时, 未知参数 β 的矩估计量.

(1) 求 $\alpha=1$ 时, 未知参数 β 的极大似然估计量.

(2) 求 $\beta=2$ 时, 未知参数 α 的极大似然估计量.

β 的矩估计量为

$$\hat{\beta} = \frac{\bar{X}}{\bar{X} - 1}.$$

解 (1) $\alpha=1$ 时, $f(x; \beta) = \begin{cases} \frac{\beta}{x^{\beta+1}}, & x > 1, \\ 0, & x \leq 1, \end{cases}$

$$L(\beta) = \prod_{i=1}^n f(x_i; \beta) = \begin{cases} \prod_{i=1}^n \frac{\beta}{x_i^{\beta+1}}, & x_i > 1, i=1, \dots, n; \\ 0, & \text{其他.} \end{cases} \quad \text{当 } x_i > 1 \text{ 时, } L(\beta) > 0, \quad 1 \leq i \leq n,$$

$$\ln L(\beta) = n \ln \beta - (\beta+1) \sum_{i=1}^n \ln x_i, \quad \text{令 } \frac{d \ln L(\beta)}{d\beta} = \frac{n}{\beta} - \sum_{i=1}^n \ln x_i = 0,$$

解得 β 的极大似然估计量: $\hat{\beta} = n / \sum_{i=1}^n \ln X_i.$

[例] (续) 设 X 的分布函数为

$$F(x; \alpha, \beta) = \begin{cases} 1 - (\frac{\alpha}{x})^\beta, & x > \alpha, \\ 0, & x \leq \alpha, \end{cases}$$

其中 $\alpha > 0, \beta > 1, X_1, \dots, X_n$ 是总体 X 的样本,

(2) 求 $\beta=2$ 时, 未知参数 α 的极大似然估计量.

解 (2) $\beta=2$ 时, $f(x; \alpha) = \begin{cases} \frac{2\alpha^2}{x^3}, & x > \alpha, \\ 0, & x \leq \alpha, \end{cases}$

$$L(\alpha) = \prod_{i=1}^n f(x_i; \alpha) = \begin{cases} \frac{2^n \alpha^{2n}}{(x_1 x_2 \cdots x_n)^3}, & x_i > \alpha, i=1, 2, \dots, n; \\ 0, & \text{其他}. \end{cases}$$

因为 $L(\alpha)$ 随 α 的增大而增大, 故应取 α 的值尽量地大;

另一方面, 由于 $L(\alpha) = 0$ 不可能是最大值, 故 α 必须满足 $x_i > \alpha$,
($1 \leq i \leq n$),

而事件 $\{ X_i > \alpha, i=1, 2, \dots, n \} = \{ \min_{1 \leq i \leq n} \{ X_i \} \geq \alpha \}$

故 α 的极大似然估计量为 $\hat{\alpha} = \min_{1 \leq i \leq n} \{ X_i \}.$

[例]多项分布参数的极大似然估计



很多情况下, 假定一个变量 X 可能取 m 个状态, $m>2$, 每个状态假定可能性为 p_1, \dots, p_m , $\sum_{i=1}^m p_i = 1$, 独立进行 n 次试验, 用 x_i 表示第 i 种状态出现的频数, x_1, \dots, x_m 会有多项分布,

$$p(x_1, \dots, x_m \mid p_1, \dots, p_m) = \frac{n!}{\prod_{i=1}^m x_i!} \prod_{i=1}^m p_i^{x_i}$$

$$l(p_1, \dots, p_m) = \log(n!) - \sum_{i=1}^m \log x_i! + \sum_{i=1}^m x_i \log p_i$$

$$\sum_{i=1}^m p_i = 1$$



$$l(p_1, \dots, p_m, \lambda) = \log(n!) - \sum_{i=1}^m \log x_i! + \sum_{i=1}^m x_i \log p_i + \lambda \left(\sum_{i=1}^m p_i - 1 \right)$$

$$\frac{\partial l(p_1, \dots, p_m, \lambda)}{\partial p_i} = \frac{x_i}{p_i} + \lambda = 0 \Rightarrow p_i = -\frac{x_i}{\lambda}, i = 1, \dots, m$$

$$\sum_{i=1}^m p_i = 1 \Rightarrow \sum_{i=1}^m -\frac{x_i}{\lambda} = 1 \Rightarrow \lambda = n$$

$$\hat{p}_i = \frac{x_i}{n}$$



极大似然估计的理论结果

$$\sqrt{nI(\theta)}(\hat{\theta}_{mle} - \theta) \xrightarrow{n \rightarrow \infty} N(0,1)$$

$$I(\theta) = E\left(\frac{\partial \log(p(x, \theta))}{\partial \theta}\right)^2 = -E\left(\frac{\partial^2 \log(p(x, \theta))}{\partial \theta^2}\right)$$

极大似然估计的分布有渐近的正态分布！

我们介绍了参数点估计, 给出了寻求估计量最常用的方法
—— 矩法和极大似然法.

计算简单
无需总体分布
不唯一、不够稳定

使用了总体分布, 质量好
计算困难

✚ 参数点估计是用一个确定的值去估计未知的参数. 看来似乎精确, 实际上把握不大.

自然要问:

样本均值、样本方差是否是一个好的估计量?
多个估计量时, 哪一个估计量更好?

这就需要讨论以下几个问题:

估计量的评选标准

- (1) 我们希望一个“好的”估计量具有什么特性?
- (2) 怎样决定一个估计量是否比另一个估计量“好”?
- (3) 应该如何寻求一个合理的估计量?



第1次作业:

- 电子书上p.109 习题二
- 2 (1) (3) (5) 、
- 4 (2) (4) (6) 、
- 5、 6、



谢谢!



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

