



# 基础数理统计

(研究生公共课)

肖柳青 教授 博士主讲



上海交通大学

SHANGHAI JIAO TONG UNIVERSITY

## 第 2 章 参数估计 (Parametric Estimation)



### 主要内容

1. 点估计的基本概念
2. 两种基本的点估计方法
3. 点估计的优良标准 (无偏性及有效估计和C-R下界)
4. 置信区间估计
5. 最佳点估计 (充分统计量)
6. 贝叶斯估计

## 2.6 贝叶斯估计 (Bayes Estimation)



- **经典学派**的观点：统计推断是根据样本信息对总体分布或总体的特征数进行推断，这里用到两种信息：**总体信息**和**样本信息**；
- **贝叶斯学派**的观点：除了上述两种信息以外，统计推断还应该使用第三种信息：**先验信息**。



- (1) **总体信息**: 总体分布提供的信息。
- (2) **样本信息**: 抽取样本所得观测值提供的信息。
- (3) **先验信息**: 人们在试验之前对要做的问题在经验上和资料上总是有所了解的, 这些信息对统计推断是有益的。先验信息即是抽样 (试验) 之前有关统计问题的一些信息。一般说来, 先验信息来源于经验和历史资料。先验信息在日常生活和工作中是很重要的。

# 举例：

某人打靶，打了5枪，枪枪中靶，


问：此人枪法如何？

某人打靶，打了500枪，枪枪中靶，

问：此人枪法如何？

经典方法：极大似然估计：100%

但是：.....



摩登神農氏

先牛奶？先茶？



台灣兩千三百萬人，如果每人每天猜一遍，每天約有23人會猜對！



# 举例

英国统计学家Savage, L. J. 曾考察了如下两个统计试验:

- (1) 一位常饮牛奶加茶的妇女声称, 她能分辨出先倒进杯子里的是茶还是牛奶. 对此做了十次试验, 她都正确地说出来.
- (2) 一位音乐家声称, 他能从一页乐谱辨别出是海顿(Haydn) 还是莫扎特(Mozart) 的作品. 在十次这样的试验中, 他都分辨正确.

在这两个统计试验中, 假如认为被试验者是在猜测, 每次成功概率为0.5, 那么十次都猜中的概率为 $2^{-10} = 0.0009766$ . 这是一个小概率事件, 是几乎不可能发生的. 因此不能认为是猜测, 而是他们的经验帮了他们的忙.

# 贝叶斯统计学



基于上述三种信息进行统计推断的统计学称为**贝叶斯统计学**。它与经典统计学的差别就在于是否利用先验信息。

贝叶斯统计在重视使用总体信息和样本信息的同时，还注意先验信息的收集、挖掘和加工，使它数量化，形成先验分布，参加到统计推断中来，以提高统计推断的质量。忽视先验信息的利用，有时是一种浪费，有时还会导出不合理的结论。

# 贝叶斯学派的基本观点




贝叶斯学派的基本观点：任一未知量  $\theta$  都可看作随机变量，可用一个概率分布去描述，这个分布称为先验分布；在获得样本之后，总体分布、样本与先验分布通过贝叶斯公式结合起来得到一个关于未知量  $\theta$  新的分布——后验分布；任何关于  $\theta$  的统计推断都应该基于  $\theta$  的后验分布进行。



# 贝叶斯统计模型

$$p(A_i | B) = \frac{p(B | A_i)p(A_i)}{p(B)} = \frac{p(B | A_i)p(A_i)}{\sum_i p(B | A_i)p(A_i)}$$

$i=1 \dots n$



- 设事件 $A_1, A_2, \dots, A_n$ 构成互不相容的事件组，贝叶斯公式如上给出，先验信息以 $\{P[A_i], i=1 \dots n\}$ 给出，即先验分布。由于事件 $B$ 的发生，可以对 $A_1, A_2, \dots, A_n$ 发生的概率重新估计。
- 贝叶斯公式综合了先验信息与试验提供的新信息，获得了后验信息，以后验概率 $\{P(A_i|B), i=1 \dots n\}$ 体现出来，**贝叶斯公式反映了先验分布向后验分布的转化。**

## 复习：条件概率



1. 定义 设 $E$ 为随机试验， $\Omega$ 为其样本空间， $A$ 、 $B$   
为任意两个事件， 若  $P(A) > 0$

则称

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为事件 $A$ 出现的情况下，事件 $B$ 的**条件概率**，或  
简称事件 $B$ 关于事件 $A$ 的**条件概率**。

## 2. 基本公式



### 定理1 (乘法公式)

假设  $A_1, A_2, \dots, A_n$  为任意  $n$  个事件 ( $n \geq 2$ ) ,

若

$$P(A_1 A_2 \cdots A_n) > 0$$

则

$$P(A_1 A_2 \cdots A_n) = P(A_1)P(A_2 | A_1)P(A_3 | A_1 A_2) \cdots \\ P(A_n | A_1 A_2 \cdots A_{n-1})$$

## 定理2 (全概率公式与贝叶斯公式)



设事件  $B_1, B_2, \dots, B_n$  两两互不相容,  $\bigcup_{i=1}^n B_i = \Omega$   
 $P(B_i) > 0 \quad i = 1, 2, \dots, n$

则 (1) 对任意事件  $A$ , 有

$$P(A) = \sum_{i=1}^n P(B_i) P(A | B_i)$$

(2) 对任意事件  $A$ , 若  $P(A) > 0$ , 有

$$P(B_i | A) = \frac{P(B_i) P(A | B_i)}{\sum_{i=1}^n P(B_i) P(A | B_i)}$$

### 3. 分布密度

连续型  
随机变量

如果对于随机变量 $X$ 的分布函数为 $F(x)$ ，存在非负的函数 $f(x)$ ，使对任意的实数 $x$ 有

$$F(x) = \int_{-\infty}^x f(t) dt$$

则称 $X$ 为连续型随机变量， $f(x)$ 称为 $X$ 的概率密度，且满足

$$f(x) \geq 0 \quad \int_{-\infty}^{+\infty} f(x) dx = 1$$



## 二、随机变量的联合分布

### 1. 联合分布函数

设  $X_1, X_2, \dots, X_n$  是样本空间  $\Omega$  的  $n$  个随机变量,  $x_1, x_2, \dots, x_n$  为任意实数, 则称

$$F(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$$

为随机变量的  $n$  维联合分布函数。

特别地

$$F(x, y) = P(X \leq x, Y \leq y)$$

即是  $X, Y$  的二维联合分布函数。

## 2. 二维分布密度

### 连续型

如果存在一个非负的二元函数  $f(x, y)$ , 使对任意的实数  $x, y$  有

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

则称  $(X, Y)$  为二维连续型随机变量,  $f(x, y)$  称为  $(X, Y)$  的概率密度, 满足:

$$f(x, y) \geq 0 \quad \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$$

## 2. 二维分布密度

### 离散型

设  $(X, Y)$  所有可能的取值为  $(x_i, y_j)$ , 而  $p_{ij}$  是  $(X, Y)$  取值为  $(x_i, y_j)$  的概率, 即

$$P(X = x_i, Y = y_j) = p_{ij} (i = 1, 2, \dots \quad j = 1, 2, \dots)$$

则称上式为二维离散型随机向量  $(X, Y)$  的联合分布律。它满足

$$p_{ij} \geq 0 \quad \sum_{i=1}^{+\infty} \sum_{j=1}^{+\infty} p_{ij} = 1$$

## 离散型

若随机变量  $(X, Y)$  的联合分布律

$$P(X = x_i, Y = y_j) = p_{ij}$$

则

$$p_{i\bullet} = P(X = x_i) = \sum_{j=1}^{\infty} p_{ij} \quad (i = 1, 2, \dots)$$

$$p_{\bullet j} = P(Y = y_j) = \sum_{i=1}^{\infty} p_{ij} \quad (j = 1, 2, \dots)$$

分别称为  $(X, Y)$  关于  $X$  和  $Y$  的边缘分布律。

$X$  和  $Y$  相互独立的充要条件是  $p_{ij} = p_{i\bullet} \cdot p_{\bullet j}$

### 3. 边缘分布及独立性

#### 边缘分布

设  $(X, Y)$  的分布函数为  $F(x, y)$ , 则  $X, Y$  的分布函数  $F_X(x)$ 、 $F_Y(y)$ , 依次称为关于  $X$  和关于  $Y$  的边缘分布函数, 且有

$$F_X(x) = F(x, +\infty) \quad F_Y(y) = F(+\infty, y)$$

#### 独立性

$$F(x, y) = F_X(x) \cdot F_Y(y)$$

则称随机变量  $X$  和  $Y$  是相互独立的。



## 连续型

若随机变量  $(X, Y)$  的概率密度为  $f(x, y)$

则

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$$

分别称为  $(X, Y)$  关于  $X$  和  $Y$  边缘概率密度。

$X$  和  $Y$  相互独立的充要条件是  $f(x, y) = f_X(x) f_Y(y)$

# 条件期望



## 一、条件期望的定义

离散型

$$E(X | Y = y_j) = \sum_{i=1}^{\infty} x_i P(X = x_i | Y = y_j)$$

其中

$$P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)}$$

连续型

$$E(X | Y = y) = \int_{-\infty}^{+\infty} x f(x | y) dx$$

其中  $f(x | y)$  条件概率密度

# 全数学期望公式



$E(X | Y)$  是随机变量 $Y$ 的函数, 当  $Y = y$  时取值  $E(X | Y = y)$   
因而它也是随机变量。

**定理1** 对一切随机变量 $X$ 和 $Y$ , 有

$$E(X) = E[E(X | Y)]$$

**离散型**

$$E(X) = \sum_{j=1}^{\infty} E(X | Y = y_j) P(Y = y_j)$$

**连续型**

$$E(X) = \int_{-\infty}^{+\infty} E(X | Y = y) f_Y(y) dy$$

# 定理1证明: $E(X) = E[E(X|Y)]$



- 证: 设  $(X, Y)$  的密度函数为  $f(x, y)$ ,  $Y$  的边缘密度为  $f_Y(y)$
- 记  $g(y) = E(X|Y=y), g(Y) = E(X|Y)$
- 注意到  $g(y) = E(X|Y=y) = \int_{-\infty}^{+\infty} xf(x|y)dx$
- 由于  $f(x, y) = f_Y(y)f(x|y)$

$$\begin{aligned} EX &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xf(x, y)dx dy = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xf_Y(y)f(x|y)dx dy \\ &= \int_{-\infty}^{+\infty} \left( \int_{-\infty}^{+\infty} xf(x|y)dx \right) f_Y(y)dy = \int_{-\infty}^{+\infty} g(y)f_Y(y)dy \\ &= E(g(Y)) = E(E(X|Y)) \end{aligned}$$

# \*方差分解公式

## 定理2

对一切随机变量 $X$ 和 $Y$ ，有

$$\text{Var}(X) = \text{Var}(E(X|Y)) + E(\text{Var}(X|Y))$$

- 首先给出条件方差的直观理解：
- 对于随机变量 $X$ ，记  $g(Y) = E(X|Y)$ ，它是 $Y$ 的函数，
- 定义  $\varepsilon = X - g(Y) = X - E(X|Y)$
- 由定理1  $\because E(g(Y)) = EX$

$$\therefore E\varepsilon = EX - E(g(Y)) = EX - E(E(X|Y)) = 0$$

- 故  $\varepsilon = X - g(Y)$  可写成回归形式

$$X = g(Y) + \varepsilon = E(X|Y) + \varepsilon$$



## 定理2证明: $Var(X) = Var(E(X|Y)) + E(Var(X|Y))$



- 证: 下面来计算 $X$ 的方差

$$Var(X) = Var(g(Y) + \varepsilon) = Var(g(Y)) + Var(\varepsilon) + 2cov(g(Y), \varepsilon)$$

$$\because cov(g(Y), \varepsilon) = E(g(Y) - E(g(Y))(\varepsilon - E\varepsilon))$$

$$cov(g(Y), \varepsilon) = 0$$

$$= E(g(Y)\varepsilon) - E(g(Y))E\varepsilon - E\varepsilon E(g(Y)) + E(g(Y))E\varepsilon$$

$$= E(g(Y)\varepsilon) - E(g(Y))E\varepsilon = E(g(Y)\varepsilon)$$

$$= E(g(Y)|Y)E(\varepsilon|Y) = E(g(Y))E(\varepsilon) = 0$$

$$\therefore Var(X) = Var(g(Y)) + Var(\varepsilon) = Var(E(X|Y)) + Var(\varepsilon)$$

续

$$\begin{aligned}\therefore \text{Var}(\varepsilon) &= E(X - g(Y))^2 \\ &= E(X^2 + g(Y)^2 - 2Xg(Y)) \\ &= E(E(X^2|Y)) - g(Y)^2 \\ &= E(\text{Var}(X|Y))\end{aligned}$$

■ 注【1】

$$\begin{aligned}EX &= E(E(X|Y)) \\ EX^2 &= E(E(X^2|Y)) \\ EX &= Eg(Y) \\ EX^2 &= Eg(Y)^2\end{aligned}$$

■ 注【2】

$$\begin{aligned}\text{Var}(X|Y) &= E((X - E(X|Y))^2|Y) \\ &= E(X^2|Y) - (E(X|Y))^2\end{aligned}$$



## 贝叶斯估计的思路：



- 1、未知参数视为随机变量： $\theta$ 
  - 数据的不可设计性与经验的不能穷尽性？
- 2、取样本 $x_1 \dots x_n$ ，求联合分布密度
  - $f(x_1, x_2, \dots, x_n; \theta)$ ， $\theta$ 是参数
- 3、联合分布密度 $\rightarrow$ 条件分布密度
  - $f(x_1, x_2, \dots, x_n / \theta)$ ， $\theta$ 是随机变量
- 4、确定 $\theta$ 的先验分布 $\pi(\theta)$
- 5、利用贝叶斯公式求后验分布密度
- 6、使用后验分布做推断（参数估计、假设检验）

# 贝叶斯公式的密度函数形式



- 总体依赖于参数  $\theta$  的概率函数在贝叶斯统计中记为  $f(x | \theta)$ ，它表示在随机变量  $\theta$  取某个给定值时总体的条件概率函数；
- 根据参数  $\theta$  的先验信息可确定先验分布  $\pi(\theta)$ ；
- 从贝叶斯观点看，样本  $x_1, x_2, \dots, x_n$  的产生分两步进行：首先从先验分布  $\pi(\theta)$  产生一个样本  $\theta_0$ ，然后从  $f(x / \theta_0)$  中产生一组样本。这时样本的联合条件概率函数
- $$f(x_1, \dots, x_n | \theta_0) = \prod_{i=1}^n f(x_i | \theta_0)$$
- 这个分布综合了总体信息和样本信息；



➤  $\theta_0$  是未知的，它是按先验分布  $\pi(\theta)$  产生的。为把先验信息综合进去，不能只考虑  $\theta_0$ ，对  $\theta$  的其它值发生的可能性也要加以考虑，故要用  $\pi(\theta)$  进行综合。这样一来，样本  $x_1, \dots, x_n$  和参数  $\theta$  的联合分布为：

$$f(x_1, x_2, \dots, x_n, \theta) = f(x_1, x_2, \dots, x_n | \theta) \pi(\theta),$$

这个联合分布把**总体信息**、**样本信息**和**先验信息**三种可用信息都综合进去了；



➤ 在没有样本信息时，人们只能依据先验分布对  $\theta$  作出推断。在有了样本观察值  $x_1, x_2, \dots, x_n$  之后，则应依据  $f(x_1, x_2, \dots, x_n, \theta)$  对  $\theta$  作出推断。由于

$$f(x_1, x_2, \dots, x_n, \theta) = \pi(\theta | x_1, x_2, \dots, x_n) f(x_1, x_2, \dots, x_n),$$

其中

$$f(x_1, \dots, x_n) = \int_{\Theta} f(x_1, \dots, x_n, \theta) d\theta = \int_{\Theta} f(x_1, \dots, x_n | \theta) \pi(\theta) d\theta$$

是  $x_1, x_2, \dots, x_n$  的边际概率函数，它与  $\theta$  无关，不含  $\theta$  的任何信息。因此能用来对  $\theta$  作出推断的仅是条件分布  $\pi(\theta | x_1, x_2, \dots, x_n)$ ，它的计算公式是

$$\pi(\theta | x_1, \dots, x_n) = \frac{f(x_1, \dots, x_n, \theta)}{f(x_1, \dots, x_n)} = \frac{f(x_1, \dots, x_n | \theta) \pi(\theta)}{\int_{\Theta} f(x_1, \dots, x_n | \theta) \pi(\theta) d\theta}$$



$$\pi(\theta|x_1, \cdots, x_n) = \frac{f(x_1, \cdots, x_n, \theta)}{f(x_1, \cdots, x_n)} = \frac{f(x_1, \cdots, x_n|\theta)\pi(\theta)}{\int_{\Theta} f(x_1, \cdots, x_n|\theta)\pi(\theta)d\theta}$$

这个条件分布称为 $\theta$  的**后验分布**，它集中了总体、样本和先验中有关 $\theta$  的一切信息。

后验分布 $\pi(\theta | x_1, x_2, \cdots, x_n)$ 的计算公式就是用密度函数表示的**贝叶斯公式**。

它是用总体和样本对先验分布 $\pi(\theta)$ 作调整的结果，贝叶斯统计的一切推断都基于后验分布进行。

Bayes统计的三个基本假设:

假设I: 总体 $X$ 有一个概率分布(pdf或pmf) $p(x; \theta)$ , 其中 $\theta$ 是参数, 不同的 $\theta$ 对应着不同的分布. 在Bayes统计中,  $p(x; \theta)$ 是给定 $\theta$ 后的一个条件概率分布, 记为 $p(x|\theta)$ .  $p(x|\theta)$ 提供的关于 $\theta$ 的信息就是总体信息.

假设II: 当给定 $\theta$ 后, 从总体 $p(x|\theta)$ 中随机抽取一个样本 $\tilde{X} = (X_1, X_2, \dots, X_n)$ , 该样本中含有的有关 $\theta$ 的信息, 就是样本信息.

当给定 $\theta$ 后, 样本的联合条件概率分布(pdf或pmf)为

$$p(\tilde{x}|\theta) = \prod_{i=1}^n p(x_i|\theta).$$

这个条件概率分布综合了总体信息和样本信息.



假设III: 未知参数 $\theta$ 是一个随机变量, 它有一个概率分布(pdf或pmf) $\pi(\theta)$ (称为先验分布). 先验分布是已知的. 先验分布提供的信息就是先验信息.

这样, 样本 $\tilde{X} = (X_1, X_2, \dots, X_n)$ 和参数的 $\theta$ 的联合概率分布是

$$p(\tilde{x}, \theta) = p(\tilde{x}|\theta)\pi(\theta).$$

这个联合概率分布综合了总体信息、样本信息和先验信息.

给定样本  $\tilde{X} = \tilde{x}$ , 由  $\tilde{X}$  和参数的  $\theta$  的联合概率分布求得参数  $\theta$  的条件概率分布

$$\begin{aligned}\pi(\theta|\tilde{x}) &= \frac{p(\tilde{x}, \theta)}{p(\tilde{x})} \\ &= \frac{p(\tilde{x}|\theta)\pi(\theta)}{\int p(\tilde{x}|\theta)\pi(\theta)d\theta} \text{——Bayes公式.}\end{aligned}$$

$\pi(\theta|\tilde{x})$  是有了试验结果后, 得到的参数  $\theta$  的条件分布, 称为后验分布 (posterior distribution). 而  $p(\tilde{x})$  是样本的边际分布.

$$\begin{array}{ccc}\tilde{X} = \tilde{x} & & \\ \vdots & & \\ \pi(\theta) & \longrightarrow & \pi(\theta|\tilde{x})\end{array}$$

Bayes方法对参数  $\theta$  的统计推断是建立在后验分布  $\pi(\theta|\tilde{x})$  的基础上的.

在Bayes公式中, 分子和分母上同乘上一个与 $\theta$ 无关的量 $h(\tilde{x})$ 不改变后验分布. 特别地如果 $T = T(\tilde{X})$ 是充分统计量,

$$p(\tilde{x}|\theta) = p(\tilde{x}|T = t)p_T(t|\theta) \propto p_T(t|\theta).$$

其中 $t = T(\tilde{x})$ . 从而

$$\pi(\theta|\tilde{x}) = \frac{p_T(t|\theta)\pi(\theta)}{\int p_T(t|\theta)\pi(\theta)d\theta} = \pi(\theta|t).$$

用充分统计量代替样本所得的后验分布是一样的.

## 例1 (后验分布的计算)

$$p(x | \theta) = \frac{1}{\sqrt{2\pi}} e^{-(x-\theta)^2/2}$$

$$\pi(\theta_0) = \pi(6) = 0.01 \quad \pi(\theta_1) = \pi(10) = 0.99$$

于是有

$$p(x) = \sum_{i=0}^1 h(x, \theta_i) = \sum_{i=0}^1 \pi(\theta_i) p(x | \theta_i) = \pi(6) p(x | 6) + \pi(10) p(x | 10)$$

$$p(8.30) = \pi(6) p(8.30 | 6) + \pi(10) p(8.30 | 10) = 0.01 \times e^{-2.30^2/2} + 0.99 \times e^{-1.70^2/2}$$

$$P(\theta = 6 | x = 8.30) = \pi(6 | 8.30)$$

$$= \frac{\pi(6) p(8.30 | 6)}{p(8.30)}$$





$$= \frac{0.01 \times e^{-2.30^2/2}}{0.01 \times e^{-2.30^2/2} + 0.99 \times e^{-1.70^2/2}} = 3.033 \times 10^{-3}$$

$$P(\theta = 10 \mid x = 8.30) = \pi(10 \mid 8.30)$$

$$= \frac{\pi(10)p(8.30 \mid 10)}{p(8.30)}$$

$$= \frac{0.99 \times e^{-1.70^2/2}}{0.01 \times e^{-2.30^2/2} + 0.99 \times e^{-1.70^2/2}} = 0.997$$



例2 设 $X$  服从参数为 $\theta$  的指数分布,  $\theta \sim \Gamma(\alpha, \beta)$  .  
有容量为1的样本  $\mathbf{x}$  . 则

$$p(x | \theta) = \theta e^{-\theta x} I_{(0, +\infty)}(x)$$

$$\pi(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta} I_{(0, +\infty)}(\theta)$$

$$h(x, \theta) = \pi(\theta) p(x | \theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^\alpha e^{-(x+\beta)\theta} I_{(0, +\infty)}(x) I_{(0, +\infty)}(\theta)$$

$$p(x) = \int_{-\infty}^{+\infty} h(x, \theta) d\theta = I_{(0, +\infty)}(x) \int_0^{+\infty} \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^\alpha e^{-(x+\beta)\theta} d\theta = \frac{\beta^\alpha (x + \beta)^{-(\alpha+1)} \Gamma(\alpha+1)}{\Gamma(\alpha)} I_{(0, +\infty)}(x)$$




故对  $x > 0$  ,

$$\pi(\theta | x) = \frac{h(x, \theta)}{p(x)} = \frac{(x + \beta)^{\alpha+1}}{\Gamma(\alpha+1)} \theta^{\alpha} e^{-(x+\beta)\theta} I_{(0,+\infty)}(\theta)$$

即

$$\pi(\theta | x) \sim \Gamma(\alpha+1, x + \beta)$$



例3 设总体  $X \sim N(\theta, \sigma^2)$ , 其中  $\theta$  未知,  $\sigma^2$  已知  $\theta \sim N(\mu, \tau^2)$ , 其中  $\mu$  和  $\tau^2$  都已知. 又设  $x_1, \dots, x_n$  为样本值. 则

$$\pi(\theta) = \frac{1}{\sqrt{2\pi\tau}} \exp\left(-\frac{(\theta - \mu)^2}{2\tau^2}\right)$$

$$p(x_1, \dots, x_n | \theta) = \left(\frac{1}{\sqrt{2\pi\sigma}}\right)^n \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2\right)$$

由此可以算出。



$$\pi(\theta | x_1, \dots, x_n) = \frac{1}{\sqrt{2\pi\tau_1}} \exp\left(-\frac{(\theta - \mu_1)^2}{2\tau_1^2}\right) \sim N(\mu_1, \tau_1^2)$$

其中

$$\mu_1 = \frac{\bar{x}\tau^2 + \mu\sigma^2/n}{\tau^2 + \sigma^2/n}$$

$$\frac{1}{\tau_1^2} = \frac{1}{\sigma^2/n} + \frac{1}{\tau^2}$$

推导见书上或者后面的例子

### 3、 贝叶斯估计

基于后验分布 $\pi(\theta|x_1, x_2, \dots, x_n)$ 对 $\theta$ 所作的贝叶斯估计有多种，常用有如下三种：

- 使用后验分布的密度函数最大值作为 $\theta$ 的点估计，称为最大后验估计；
- 使用后验分布的中位数作为 $\theta$ 的点估计，称为后验中位数估计；
- 使用后验分布的均值作为 $\theta$ 的点估计，称为后验期望估计。用得最多的是后验期望估计，它一般也简称为贝叶斯估计，记为 $\hat{\theta}_B$ 。

$$\hat{\theta}_B(\tilde{x}) = E(\theta|\tilde{x}) = \int \theta \pi(\theta|\tilde{x}) d\theta.$$

**定义1** 设 $a = a(x)$ 为决策,  $L(\theta, a)$ 为损失函数. 称

$$c(x, a) = \int_{\Theta} L(\theta, a) \pi(\theta | x) d\theta$$

为决策 $a$  的后验期望损失. 称对所有满足  $p(x) > 0$  的 $x$ , 使得  $c(x, a)$  有最小值的决策  $a(x)$ , 或等价地, 使得

$$\int_{\Theta} L(\theta, a) p(x | \theta) \pi(\theta) d\theta$$

有最小值的决策  $a(x)$  (因为  $\pi(x) p(x | \theta) = p(x) \pi(\theta | x)$ ), 为该统计问题的贝叶斯决策 (函数). 在估计问题中, 它又称为贝叶斯估计。



因为贝叶斯决策使得后验期望损失达到最小, 所以从经济的角度考虑, 贝叶斯决策是一个好的决策.

定理2.5.1 1) 在平方损失函数  $L(\theta, a) = (a - \theta)^2$  下,  $\theta$  的贝叶斯估计为后验期望值

$$E(\theta | x) = \int_{\Theta} \theta \pi(\theta | x) d\theta$$

2) 在平方损失函数的加权函数  $L(\theta, a) = \lambda(\theta)(a - \theta)^2$  下,  $\theta$  的贝叶斯估计为

$$\frac{E[\lambda(\theta)\theta | x]}{E[\lambda(\theta) | x]}$$

证 仅证1), 用类似的方法可以证明2). 由于

$$\begin{aligned} c(x, a) &= \int_{\Theta} L(\theta, a) \pi(\theta | x) d\theta = \int_{\Theta} (a - \theta)^2 \pi(\theta | x) d\theta \\ &= a^2 \int_{\Theta} \pi(\theta | x) d\theta - 2a \int_{\Theta} \theta \pi(\theta | x) d\theta + \int_{\Theta} \theta^2 \pi(\theta | x) d\theta \\ &= a^2 - 2a \int_{\Theta} \theta \pi(\theta | x) d\theta + \int_{\Theta} \theta^2 \pi(\theta | x) d\theta \end{aligned}$$

是关于  $a$  的二次三项式, 不难知道, 当  
 $a = \int_{\Theta} \theta \pi(\theta | x) d\theta$  时  $c(a, x)$  有最小值

例. 设某事件A在一次试验中发生的概率为 $\theta$ ，为估计 $\theta$ ，对试验进行了 $n$ 次独立观测，其中事件A发生了 $X$ 次，显然  $X|\theta \sim B(n, \theta)$ ，即

$$f(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n$$

$\theta$ 的极大似然估计值为

$$\hat{\theta}_{MLE} = \frac{x}{n} \quad \text{———经典统计学派的估计.}$$

假若我们在试验前对事件A没有什么了解，从而对其发生的概率 $\theta$ 也没有任何信息。在这种场合，贝叶斯本人建议采用“同等无知”的原则使用区间 $(0,1)$ 上的均匀分布 $U(0,1)$ 作为 $\theta$ 的先验分布，因为它取 $(0,1)$ 上的每一点的机会均等。

贝叶斯的这个建议被后人称为贝叶斯假设。

由此即可利用贝叶斯公式求出 $\theta$ 的后验分布。具体如下：先写出 $X$ 和 $\theta$ 的联合分布

$$f(x, \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n, \quad 0 < \theta < 1$$

然后求 $X$ 的边际分布

$$f(x_1, \dots, x_n) = \int_{\Theta} f(x_1, \dots, x_n, \theta) d\theta = \int_{\Theta} \binom{n}{x} \theta^x (1 - \theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}$$

最后求出 $\theta$ 的后验分布

$$\pi(\theta|x) = \frac{f(x, \theta)}{f(x)} = \frac{\Gamma(n+2)}{\Gamma(x+1)\Gamma(n-x+1)} \theta^{(x+1)-1} (1-\theta)^{(n-x+1)-1}, \quad 0 < \theta < 1$$

最后的结果说明 $\theta|X \sim Be(x+1, n-x+1)$ ，其后验期望估计为

$$\hat{\theta}_B = E(\theta|x) = \frac{x+1}{n+2}$$

$$f(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}, \quad 0 \leq x \leq 1$$

$$\beta(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)} = \int_0^1 t^{a-1} (1-t)^{b-1} dt$$

$$E(X) = \frac{a}{a+b};$$
$$Var(X) = \frac{ab}{(a+b)^2(a+b+1)}$$

某些场合，贝叶斯估计要比极大似然估计更合理一点。比如：“抽检3个全是合格品”与“抽检10个全是合格品”，后者的质量比前者更信得过。这种差别在不合格品率的极大似然估计中反映不出来（两者都为0），而用贝叶斯估计两者分别是0.2 和 0.083。

由此可以看到，在这些极端情况下，贝叶斯估计比极大似然估计更符合人们的理念。

## 另一种更简洁做法:



为求Bayes估计, 先给定一个先验分布 $\pi(\theta)$ , 然后求后验分布

$$\pi(\theta|x) = \frac{\binom{n}{x} \theta^x (1-\theta)^{n-x} \pi(\theta)}{\int \binom{n}{x} \theta^x (1-x)^{n-x} \pi(\theta) d\theta} \propto_{\theta} \theta^x (1-\theta)^{n-x} \pi(\theta).$$



然后求后验期望就得到Bayes估计

$$\hat{\theta}_B = \int \theta \pi(\theta|x) d\theta = \frac{\int \theta \theta^x (1-\theta)^{n-x} \pi(\theta) d\theta}{\int \theta^x (1-x)^{n-x} \pi(\theta) d\theta}.$$

## 先验分布的选取:

### 1. ”同等无知”

在没有先验信息的情况下, 对未知参数 $\theta$ 的所有可能取值同等对待. 现 $\theta$ 取值范围为 $[0, 1]$ , 故在没有先验信息的情况下, 取均匀分布 $U[0, 1]$ 作为先验分布:

$$\pi(\theta) = 1; \quad 0 \leq \theta \leq 1.$$

这时Bayes估计为

$$\hat{\theta}_B = \frac{\int \theta \theta^x (1 - \theta)^{n-x} d\theta}{\int \theta^x (1 - x)^{n-x} d\theta} = \frac{x + 1}{n + 2}.$$





No.	$n$	$x$	$\hat{\theta}_{MLE} = \frac{x}{n}$	$\hat{\theta}_B = \frac{x+1}{n+2}$
1	5	5	1	0.867
2	20	20	1	0.955
3	5	0	0	0.143
4	20	0	0	0.045

**2. 共轭分布法** 我们希望先验分布和后验分布是同类型的分布, 即它们在同一个分布族中. 这样的分布族称为样本(或统计量)的分布族的共轭分布族(conjugate family).

现在

$$\pi(\theta|x) \propto_{\theta} \theta^x (1 - \theta)^{n-x} \pi(\theta).$$

为使得先验分布和后验分布有同类型的分布, 我们有

$$\pi(\theta) \propto_{\theta} \theta^{a-1} (1 - \theta)^{b-1}.$$

因此取beta分布作为先验分布, beta分布族作为先验分布族.

$$\pi(\theta) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1 - \theta)^{b-1}; \quad 0 \leq \theta \leq 1.$$

这时

$$\pi(\theta|x) \propto_{\theta} \theta^{x+a-1} (1 - \theta)^{n-x+b-1}.$$

## Bayes估计为

$$\hat{\theta}_B = E[beta(x + a, n - x + b)] = \frac{x + a}{n + a + b}.$$

$\hat{\theta}_B$ 可写成

$$\hat{\theta}_B = \frac{n}{a + b + n} \cdot \hat{\theta}_{MLE} + \frac{a + b}{a + b + n} \cdot \frac{a}{a + b}.$$

它是先验期望 $a/(a + b)$ 和MLE $\hat{\theta}_{MLE}$ 的加权平均.

$n$ 小时, 先验信息在估计中占主要地位;  $n$ 大时, 试验信息在估计中占主要地位.

参数 $a, b$ 不同, 对应的先验分布也不同, 得到的Bayes估计也不同.  $a, b$ 可以通过先验信息估计出来.

参数 $a, b$ 不同,对应的先验分布也不同,得到的Bayes估计也不同.  $a, b$ 可以通过先验信息估计出来.

例如: 1. 如果知道 $\theta$ 的均值 $\bar{\theta}$ 和方差 $s_{\theta}^2$ , 则可由下列方程解出 $a, b$ :

$$\begin{cases} \frac{a}{a+b} = \bar{\theta}, \\ \frac{ab}{(a+b)^2(a+b+1)} = s_{\theta}^2. \end{cases}$$

2. 如果知道 $\theta$ 的分位数, 则也可解出 $a, b$ ; 如

$$\begin{cases} \int_0^{\theta_{0.1}} \pi(\theta) d\theta = 0.1, \\ \int_0^{\theta_{0.5}} \pi(\theta) d\theta = 0.5. \end{cases}$$

3. 如果根据先验信息只能获得先验均值 $\theta$ . 可令

$$\frac{a}{a+b} = \bar{\theta}.$$

但从一个方程不能唯一确定两个未知参数.

方差

$$\text{Var}(\theta) = \frac{ab}{(a+b)^2(a+b+1)} = \frac{\bar{\theta}(1-\bar{\theta})}{a+b+1}$$

随 $a+b$ 的增大而减少, 方差减少意味着概率向均值 $E(\theta) = \bar{\theta}$ 集中, 从而提高了 $E(\theta) = \bar{\theta}$ 的确信程度. 这样以来, 选择 $a+b$ 的问题转化为决策人对 $E(\theta) = \bar{\theta}$ 的确信程度大小的问题. 如果对 $E(\theta) = \bar{\theta}$ 很确信, 那么 $a+b$ 可选得大一些, 否则就选得小一些.

## Beta 分布中参数与方差的关系

Beta分布	$a$	$a + b$	$E(\theta)$	$Var(\theta)$
beta(2,3)	2	5	0.4	0.0400
beta(4,6)	4	10	0.4	0.0218
beta(8,12)	8	20	0.4	0.0114
beta(10,15)	10	25	0.4	0.0092
beta(14,21)	14	35	0.4	0.0067




**例.** 设  $x_1, x_2, \dots, x_n$  是来自正态分布  $N(\mu, \sigma_0^2)$  的一个样本, 其中  $\sigma_0^2$  已知,  $\mu$  未知, 假设  $\mu$  的先验分布亦为正态分布  $N(\theta, \tau^2)$ , 其中先验均值  $\theta$  和先验方差  $\tau^2$  均已知, 试求  $\mu$  的贝叶斯估计。

**解:** 样本  $x$  的分布和  $\mu$  的先验分布分别为

$$f(x|\mu) = (2\pi\sigma_0^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}$$
$$\pi(\mu) = (2\pi\tau^2)^{-1/2} \exp \left\{ -\frac{1}{2\tau^2} (\mu - \theta)^2 \right\}$$



由此可以写出 $x$ 与 $\mu$ 的联合分布


$$f(x, \mu) = k_1 \cdot \exp \left\{ -\frac{1}{2} \left[ \frac{n\mu^2 - 2n\mu\bar{x} + \sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\mu^2 - 2\theta\mu + \theta^2}{\tau^2} \right] \right\}$$


其中  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  ,  $k_1 = (2\pi)^{-(n+1)/2} \tau^{-1} \sigma_0^{-n}$  若记

$$A = \frac{n}{\sigma_0^2} + \frac{1}{\tau^2}, \quad B = \frac{n\bar{x}}{\sigma_0^2} + \frac{\theta}{\tau^2}, \quad C = \frac{\sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\theta^2}{\tau^2}$$

则有

$$\begin{aligned} f(x, \mu) &= k_1 \exp \left\{ -\frac{1}{2} [A\mu^2 - 2B\mu + C] \right\} \\ &= k_1 \exp \left\{ -\frac{(\mu - B/A)^2}{2/A} - \frac{1}{2} (C - B^2/A) \right\} \end{aligned}$$

注意到 $A, B, C$ 均与 $\mu$ 无关，由此容易算得样本的边际密度函数


$$f(x) = \int_{-\infty}^{\infty} f(x, \mu) d\mu = k_1 \exp \left\{ -\frac{1}{2} (C - B^2/A) \right\} (2\pi/A)^{1/2}$$

应用贝叶斯公式即可得到后验分布

$$\pi(\mu|x) = \frac{f(x, \mu)}{f(x)} = (2\pi/A)^{1/2} \exp \left\{ -\frac{1}{2/A} (\mu - B/A)^2 \right\}$$

这说明在样本给定后， $\mu$ 的后验分布为

$N(B/A, 1/A)$ ，即

$$\mu|x \sim N \left( \frac{n\bar{x}\sigma_0^{-2} + \theta\tau^{-2}}{n\sigma_0^{-2} + \tau^{-2}}, \frac{1}{n\sigma_0^{-2} + \tau^{-2}} \right)$$

后验均值即为其贝叶斯估计:

$$\hat{\mu} = \frac{n/\sigma_0^2}{n/\sigma_0^2 + 1/\tau^2} \bar{x} + \frac{1/\tau^2}{n/\sigma_0^2 + 1/\tau^2} \theta$$

它是样本均值  $\bar{x}$  与先验均值  $\theta$  的加权平均。



## Example

在儿童智商测验中, 儿童的智商  $X \sim N(\theta, 100)$ ,  
而  $\theta \sim N(100, 225)$ . 一儿童在一次智商测验中得  $x = 115$  分,  
求  $\theta$  的 Bayes 估计.

$$\hat{\theta}_B = \frac{x(100)^{-1} + 100(225)^{-1}}{(100)^{-1} + (225)^{-1}} = \frac{400 + 9x}{13} = 110.38.$$

# 共轭先验分布

设 $\theta$ 是某分布的一个参数,  $\pi(\theta)$ 是其先验分布. 假如由抽样信息算得的后验分布 $\pi(\theta|\tilde{x})$ 与 $\pi(\theta)$ 是属于一个分布族, 则称 $\pi(\theta)$  是 $\theta$  的共轭先验分布.

## 常用的共轭先验分布

总体分布	参数	共轭先验分布
二项分布	成功概率	beta分布
泊松分布	均值	gamma分布
指数分布	均值	倒gamma分布
指数分布	均值倒数	gamma分布
正态分布(方差已知)	均值	正态分布
正态分布(均值已知)	方差	倒gamma分布

## 例.指数分布



彩电的寿命服从指数分布, 它的密度函数为

$$p(t|\theta) = \frac{1}{\theta} e^{-t/\theta}, \quad t > 0.$$

其中,  $\theta > 0$  是彩电的平均寿命. 现从一批彩电中随机抽取  $n$  台进行奉命试验. 试验到第  $r$  台失效时为止. 记录失效时间为  $t_{(1)} \leq t_{(2)} \leq \cdots \leq t_{(r)}$ . 另外,  $n - r$  台直到试验停止时还没失效. 求  $\theta$  的 Bayes 估计.

设 $(T_1, T_2, \dots, T_n)$ 为抽取的 $n$ 台彩电的寿命,  $t_{(1)}, t_{(2)}, \dots, t_{(r)}$ 是观察到的前 $r$ 个次序统计量 $T_{(1)}, T_{(2)}, \dots, T_{(r)}$ 的观察值.  
 $(T_{(1)}, T_{(2)}, \dots, T_{(r)})$  是截断样本, 这个截断样本的密度函数为

$$\begin{aligned} p(t_{(1)}, \dots, t_{(r)} | \theta) &\propto_{\theta} \prod_{i=1}^r (\theta^{-1} e^{-t_{(i)}/\theta}) \cdot [e^{-t_{(r)}/\theta}]^{n-r} \\ &= \theta^{-r} \exp\{-s/\theta\}. \end{aligned}$$

其中 $s = t_{(1)} + \dots + t_{(r)} + (n - r)t_{(r)}$ 为总试验时间.

若设 $\pi(\theta)$ 为先验分布, 则后验分布为

$$\pi(\theta|t_{(1)}, \cdots, t_{(r)}) \propto_{\theta} \theta^{-r} \exp\{-s/\theta\} \pi(\theta).$$

为使得 $\pi(\theta)$ 和 $\pi(\theta|t_{(1)}, \cdots, t_{(r)})$ 有同样的形式, 应取

$$\pi(\theta) \propto_{\theta} \theta^{-(a+1)} \exp\{-b/\theta\}.$$

即

$$\pi(\theta) = \frac{b^a}{\Gamma(a)} \theta^{-(a+1)} \exp\{-b/\theta\}, \quad \theta > 0.$$

这样的密度函数是倒gamma分布的密度函数, 记为 $\Gamma^{-1}(a, b)$ .



易得

$$\mathbb{E}[\Gamma^{-1}(a, b)] = \frac{b}{a - 1}.$$

现在后验密度函数为

$$\pi(\theta|t_{(1)}, \cdots, t_{(r)}) \propto_{\theta} \theta^{-(a+r+1)} \exp\{-(b+s)/\theta\}, \quad \theta > 0.$$

即  $\pi(\theta|t_{(1)}, \cdots, t_{(r)}) \sim \Gamma^{-1}(a+r, b+s)$ . Bayes估计为

$$\hat{\theta}_B = \mathbb{E}[\Gamma^{-1}(a+r, b+s)] = \frac{b+s}{a+r-1}.$$

根据已掌握的资料,我国已做了大量的彩电寿命试验,由这些试验数据可估算出彩电的平均寿命不低于30000小时,10%分位数 $\theta_{0.1}$ 大约为11250小时. 这样解方程

$$\begin{cases} \frac{b}{a-1} = 30000 \\ \int_0^{\theta_{0.1}} \pi(\theta) d\theta = 0.1. \end{cases}$$

得

$$a = 1.956, \quad b = 2868.$$

从而

$$\hat{\theta}_B = \frac{2868 + s}{0.956 + r}.$$



## 加权平均均方误差与Bayes 估计

设 $\theta$ 为待估参数,  $\tilde{X}$ 为一个样本.

证明: 在均方误差意义下,  $\theta$ 的最优估计量不存在. 即, 不存在这样的估计量 $\delta(\tilde{X})$ 使得

$$E_{\theta}\{\theta - \delta(\tilde{X})\}^2 \text{ 关于 } \theta \text{ 一致地最小.}$$

而将寻找范围缩小到无偏估计类时, 这样的最优估计量在一定条件下存在且唯一;

下面我们换一个角度思考最优估计的问题. 我们不需要

$$R(\theta, \delta) = \mathbb{E}_{\theta}\{\theta - \delta(\tilde{X})\}^2 \text{ 关于 } \theta \text{ 一致地最小.}$$

而考察使得均方误差  $R(\theta, \delta)$  关于  $\theta$  的加权平均最小的问题:

$$\min_{\delta} \int R(\theta, \delta) \pi(\theta) d\theta.$$

$\pi(\theta) \geq 0$  是某个给定的权函数. 我们不妨设

$$\int \pi(\theta) d\theta = 1.$$

这样  $\pi(\theta)$  可以看做一个概率密度. 记样本的概率密度(pdf)或分布列(pmf)为  $p(\tilde{x}|\theta)$ .

则

$$\int R(\theta, \delta) \pi(\theta) d\theta = \int \int \{\theta - \delta(\tilde{x})\}^2 p(\tilde{x}|\theta) \pi(\theta) d\tilde{x} d\theta.$$

这恰好是将  $\theta \sim \pi(\theta)$  看作随机变量时, 在Bayes意义下,  $(\tilde{X}, \theta)$  之函数  $\{\theta - \delta(\tilde{X})\}^2$  的期望, 即

$$\int R(\theta, \delta) \pi(\theta) d\theta = \mathbb{E}\{\theta - \delta(\tilde{X})\}^2.$$

$\mathbb{E}\{\theta - \delta(\tilde{X})\}^2$  称为Bayes风险.

如果写  $p(\tilde{x}|\theta)\pi(\theta) = \pi(\theta|\tilde{x})p(\tilde{x})$ , 其中  $\pi(\theta|\tilde{x})$  是  $\theta$  的后验分布,  $p(\tilde{x})$  是  $\tilde{X}$  的边缘分布, 那么

$$\begin{aligned}\int R(\theta, \delta)\pi(\theta)d\theta &= \mathbb{E}\{\theta - \delta(\tilde{X})\}^2 \\ &= \int \left[ \int \{\theta - \delta(\tilde{x})\}^2 \pi(\theta|\tilde{x})d\theta \right] p(\tilde{x})d\tilde{x} \\ &= \int \mathbb{E} \left[ \{\theta - \delta(\tilde{x})\}^2 | \tilde{X} = \tilde{x} \right] p(\tilde{x})d\tilde{x}.\end{aligned}$$

$\mathbb{E} \left[ \{\theta - \delta(\tilde{x})\}^2 | \tilde{X} = \tilde{x} \right]$  称为后验期望损失 (posterior expected loss).

为  $\int R(\theta, \delta)\pi(\theta)d\theta$  最小, 只要

$$\min_{\delta(\tilde{x})} \mathbf{E} \left[ \{\theta - \delta(\tilde{x})\}^2 | \tilde{X} = \tilde{x} \right].$$

而

$$\arg \min_{\delta(\tilde{x})} \mathbf{E} \left[ \{\theta - \delta(\tilde{x})\}^2 | \tilde{X} = \tilde{x} \right] = \mathbf{E}[\theta | \tilde{X} = \tilde{x}] = \int \theta \pi(\theta | \tilde{x}) d\theta$$

即为后验期望, 这就是Bayes 估计.

所以

$$\mathbf{E}[\theta | \tilde{X} = \tilde{x}] = \arg \min_{\delta(\tilde{x})} \int R(\theta, \delta) \pi(\theta) d\theta.$$

即

$$\mathbf{E}[\theta | \tilde{X}] = \arg \min_{\delta(\tilde{X})} \int \mathbf{E}_{\theta} \{ \theta - \delta(\tilde{X}) \}^2 \pi(\theta) d\theta.$$



**结论** 对给定的权函数 $\pi(\theta)$ , 在加权均方误差(或称 $Bayes$ 均方风险意义)下, 期望型 $Bayes$ 估计是最优估计.

即

$$\begin{aligned} & \arg \min_{\delta(\tilde{x})} \int \mathbb{E}_{\theta}(\theta - \delta(\tilde{X}))^2 \pi(\theta) d\theta \\ &= \arg \min_{\delta(\tilde{x})} \mathbb{E} \left[ (\theta - \delta(\tilde{X}))^2 \mid \tilde{X} = \tilde{x} \right] \\ &= \mathbb{E}[\theta \mid \tilde{x}] = \text{mean of } \pi(\theta \mid \tilde{x}). \end{aligned}$$



例 1 某厂生产电子元件，从过去的每批产品得到次品率的概率分布如下表

次品率 $p$	0.02	0.05	0.10	0.15	0.20
概率 $P$	0.4	0.3	0.15	0.10	0.05

现有一批产品需要出厂，厂方没有作 100% 的检验，只是抽样 20 件，检查结果其中有一件为次品。假定损失函数为误差的平方，即  $L(p, d) = (p - d)^2$ ，试求次品率的贝叶斯估计。

解：总体  $X$  为一批产品中的次品数，则总体  $X \sim b(1, p)$ ，其中  $p \in \Theta = \{0.02, 0.05, 0.10, 0.15, 0.20\}$ 。

样本  $(X_1, \dots, X_n)$ ，样本观测值  $(x_1, \dots, x_n)$ ， $n = 20$

参数  $p$  的后验分布：

$$P(\theta=t|X_1=x_1, \dots, X_n=x_n) = \frac{P(\theta=t) \prod_{i=1}^n P(X_i=x_i|\theta=t)}{\sum_{t \in \Theta} P(\theta=t) \prod_{i=1}^n P(X_i=x_i|\theta=t)} = \frac{P(\theta=t) \prod_{i=1}^n t^{x_i} (1-t)^{1-x_i}}{\sum_{t \in \Theta} P(\theta=t) \prod_{i=1}^n t^{x_i} (1-t)^{1-x_i}} = \frac{P(\theta=t) t^{\sum_{i=1}^n x_i} (1-t)^{n-\sum_{i=1}^n x_i}}{\sum_{t \in \Theta} P(\theta=t) t^{\sum_{i=1}^n x_i} (1-t)^{n-\sum_{i=1}^n x_i}}$$

参数  $p$  的贝叶斯估计：

$$p^*(x_1, \dots, x_n) = E(p|x_1, \dots, x_n) = \sum_{t \in \Theta} t P(p=t|X_1=x_1, \dots, X_n=x_n) = \frac{\sum_{t \in \Theta} t P(p=t) t^{\sum_{i=1}^n x_i} (1-t)^{n-\sum_{i=1}^n x_i}}{\sum_{t \in \Theta} P(p=t) t^{\sum_{i=1}^n x_i} (1-t)^{n-\sum_{i=1}^n x_i}}$$

将  $\sum_{i=1}^n x_i = 1$ ， $n = 20$  及  $\theta$  的先验分布代入上式可得次品率的贝叶斯估计  $\hat{p} = 0.052$ 。

例 2 总体  $X \sim b(1, p)$ ，参数  $p$  未知且  $p \sim U[0,1]$ ，样本  $(X_1, \dots, X_n)$ ，损失函数是平方损

失函数  $L(p, d) = (p - d)^2$ ，求参数  $p$  的贝叶斯估计和贝叶斯风险。

解：  $f(x|p) = p^x (1 - p)^{1-x}, x = 0, 1$

$p$  的后验分布 
$$h(p|x_1, \dots, x_n) = \frac{\pi(p) \prod_{i=1}^n P(X_i = x_i | p)}{\int_{\theta \in \Theta} \pi(p) \prod_{i=1}^n P(X_i = x_i | p) dp}, \quad 0 \leq p \leq 1$$

$$\pi(p) = \begin{cases} 1, & 0 \leq p \leq 1 \\ 0, & otherwise \end{cases}, \quad \prod_{i=1}^n P(X_i = x_i | p) = \prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}$$

$$\begin{aligned} \int_{\theta \in \Theta} \pi(p) \prod_{i=1}^n P(X_i = x_i | p) dp &= \int_{-\infty}^{+\infty} \pi(p) q(x_1, \dots, x_n | p) dp = \int_0^1 p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i} dp \\ &= B(\sum_{i=1}^n x_i + 1, n - \sum_{i=1}^n x_i + 1) = \frac{\Gamma(\sum_{i=1}^n x_i + 1) \Gamma(n - \sum_{i=1}^n x_i + 1)}{\Gamma(n + 2)} \end{aligned}$$

$p$  的后验分布：

$$h(p|x_1, \dots, x_n) = \frac{p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}}{\frac{\Gamma(\sum_{i=1}^n x_i + 1) \Gamma(n - \sum_{i=1}^n x_i + 1)}{\Gamma(n+2)}} = \frac{\Gamma(n+2)}{\Gamma(\sum_{i=1}^n x_i + 1) \Gamma(n - \sum_{i=1}^n x_i + 1)} p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}, \quad 0 \leq p \leq 1$$

$$\text{即 } p|(x_1, \dots, x_n) \sim Be(\sum_{i=1}^n x_i + 1, n+1 - \sum_{i=1}^n x_i)$$

$$p \text{ 的贝叶斯估计: } p^*(x_1, \dots, x_n) = E(p|x_1, \dots, x_n) = \frac{\sum_{i=1}^n x_i + 1}{n+2} = \frac{n\bar{x} + 1}{n+2}.$$

$$\text{贝叶斯风险 } R_B(p^*) = E[R(p, p^*)] = E[E(L(p, p^*)|p)]$$

$$\begin{aligned} E(L(p, p^*)|p) &= E((p - p^*)^2|p) = E\left((p - \frac{n\bar{X} + 1}{n+2})^2 \middle| p\right) = E\left(p^2 - 2p\left(\frac{n\bar{X} + 1}{n+2}\right) + \left(\frac{n\bar{X} + 1}{n+2}\right)^2 \middle| p\right) \\ &= p^2 - 2pE\left(\frac{n\bar{X} + 1}{n+2}\right) + E\left(\frac{n\bar{X} + 1}{n+2}\right)^2 = p^2 - 2p\left(\frac{nE\bar{X} + 1}{n+2}\right) + \frac{(n^2 E\bar{X}^2 + 2nE\bar{X} + 1)}{(n+2)^2} \\ &= p^2 - 2p\left(\frac{np + 1}{n+2}\right) + \frac{\left(n^2(\frac{p(1-p)}{n} + p^2) + 2np + 1\right)}{(n+2)^2} = \frac{-(n-4)p^2 + (n-4)p + 1}{(n+2)^2} \end{aligned}$$

$$\begin{aligned} R_B(p^*) &= E[E(L(p, p^*)|p)] = E\left[\frac{-(n-4)p^2 + (n-4)p + 1}{(n+2)^2}\right] = \frac{-(n-4)Ep^2 + (n-4)Ep + 1}{(n+2)^2} \\ &= \frac{-(n-4)\left[\frac{1}{12} + \left(\frac{1}{2}\right)^2\right] + \frac{1}{2}(n-4) + 1}{(n+2)^2} = \frac{\frac{1}{6}(n-4) + 1}{(n+2)^2} = \frac{1}{6(n+2)} \end{aligned}$$

注：(1) 经典估计  $\hat{p} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。在  $\sum_{i=1}^n X_i = 0$ ，即样本均是废品时，估计正品率  $\hat{p} = 0$ ；

在  $\sum_{i=1}^n X_i = n$ ，即样本中无废品时，估计正品率  $\hat{p} = 1$ 。这样的估计似乎太极端了，有点不

切实际，但当样本容量  $n$  较小时，这样的情形难以避免。而贝叶斯估计  $\hat{p} = \frac{1}{n+2}$  或

$\hat{p} = \frac{n+1}{n+2}$ ，这样的估计留有余地，给人以比较可靠之感。

(2) 经典估计  $\hat{p} = \bar{X}$ ，其贝叶斯风险

$$\begin{aligned} R_B(\hat{p}) &= E[R(p, \hat{p})] = E[E(L(p, \hat{p}) | p)] = E[E((p - \hat{p})^2 | p)] = E[E((p - \bar{X})^2 | p)] \\ &= E[E(p^2 - 2p\bar{X} + \bar{X}^2 | p)] = E[p^2 - 2pE\bar{X} + E\bar{X}^2] = E\left[p^2 - 2p \cdot p + \left(\frac{p(1-p)}{n} + p^2\right)\right] \\ &= E\left[\frac{p(1-p)}{n}\right] = \frac{E[p(1-p)]}{n} = \frac{Ep - Ep^2}{n} = \frac{\frac{1}{2} - \left(\frac{1}{12} + \left(\frac{1}{2}\right)^2\right)}{n} = \frac{1}{6n} \end{aligned}$$

例 3 假设总体  $X \sim N(\mu, \sigma^2)$ ,  $\sigma^2$  已知,  $\mu \sim N(\tau, v^2)$ , 样本  $(X_1, \dots, X_n)$ , 损失函数

$L(\mu, d) = (\mu - d)^2$ , 求参数  $\mu$  的贝叶斯估计和贝叶斯风险。

解:  $f(x|\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < +\infty$

$\mu$  的后验分布  $h(\mu|x_1, \dots, x_n) = \frac{\pi(\mu) \prod_{i=1}^n p(x_i|\mu)}{\int_{-\infty}^{+\infty} \pi(\mu) \prod_{i=1}^n p(x_i|\mu) d\mu}, -\infty < \mu < +\infty$

$$\pi(\mu) = \frac{1}{\sqrt{2\pi v^2}} e^{-\frac{(\mu-\tau)^2}{2v^2}}, -\infty < \mu < +\infty, \quad \prod_{i=1}^n p(x_i|\mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i-\mu)^2}$$

$$\begin{aligned} \int_{-\infty}^{+\infty} \pi(\mu) \prod_{i=1}^n p(x_i|\mu) d\mu &= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi v^2}} e^{-\frac{(\mu-\tau)^2}{2v^2}} (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i-\mu)^2} d\mu \\ &= \frac{1}{\sqrt{2\pi v^2}} (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{\tau^2}{2v^2} - \frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \frac{(\tau\sigma^2 + n\bar{x}v^2)^2}{2v^2\sigma^2(nv^2 + \sigma^2)} \right\} \\ &\quad \times \int_{-\infty}^{+\infty} \exp \left\{ -\frac{(nv^2 + \sigma^2)}{2v^2\sigma^2} \left( \mu - \frac{\tau\sigma^2 + n\bar{x}v^2}{nv^2 + \sigma^2} \right)^2 \right\} d\mu \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \left( \frac{nv^2 + \sigma^2}{\sigma^2} \right)^{-\frac{1}{2}} \exp \left\{ -\frac{\tau^2}{2v^2} - \frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \frac{(\tau\sigma^2 + n\bar{x}v^2)^2}{2v^2\sigma^2(nv^2 + \sigma^2)} \right\} \end{aligned}$$

$\mu$  的后验分布:

$$h(\mu|x_1, \dots, x_n) = \frac{1}{\sqrt{\frac{2\pi v^2 \sigma^2}{nv^2 + \sigma^2}}} \exp \left\{ -\frac{\left( \mu - \frac{\tau\sigma^2 + n\bar{x}v^2}{nv^2 + \sigma^2} \right)^2}{\frac{2v^2\sigma^2}{nv^2 + \sigma^2}} \right\}, \quad \mu|(x_1, \dots, x_n) \sim N\left( \frac{\tau\sigma^2 + nv^2\bar{x}}{nv^2 + \sigma^2}, \frac{v^2\sigma^2}{nv^2 + \sigma^2} \right)$$

$\mu$  的贝叶斯估计:  $\mu^*(x_1, \dots, x_n) = E(\mu|x_1, \dots, x_n) = \frac{\tau\sigma^2 + nv^2\bar{x}}{nv^2 + \sigma^2}$

贝叶斯风险  $R_B(\mu^*) = E[R(\mu, \mu^*)] = E[E(L(\mu, \mu^*)|\mu)]$

$$\begin{aligned} E(L(\mu, \mu^*)|\mu) &= E((\mu - \mu^*)^2|\mu) = E\left(\left(\mu - \frac{\tau\sigma^2 + nv^2\bar{X}}{nv^2 + \sigma^2}\right)^2 \middle| \mu\right) = E\left(\mu^2 - 2\mu\left(\frac{\tau\sigma^2 + nv^2\bar{X}}{nv^2 + \sigma^2}\right) + \left(\frac{\tau\sigma^2 + nv^2\bar{X}}{nv^2 + \sigma^2}\right)^2 \middle| \mu\right) \\ &= \mu^2 - 2\mu E\left(\frac{\tau\sigma^2 + nv^2\bar{X}}{nv^2 + \sigma^2}\right) + E\left(\frac{\tau\sigma^2 + nv^2\bar{X}}{nv^2 + \sigma^2}\right)^2 = \mu^2 - 2\mu\left(\frac{\tau\sigma^2 + nv^2 E\bar{X}}{nv^2 + \sigma^2}\right) + \frac{E(\tau\sigma^2 + nv^2\bar{X})^2}{(nv^2 + \sigma^2)^2} \\ &= \mu^2 - 2\mu\left(\frac{\tau\sigma^2 + nv^2\mu}{nv^2 + \sigma^2}\right) + \frac{(\tau\sigma^2)^2 + 2(\tau\sigma^2)(nv^2)\mu + (nv^2)^2\left(\frac{\sigma^2}{n} + \mu^2\right)}{(nv^2 + \sigma^2)^2} \\ &= \left[\frac{\sigma^2}{nv^2 + \sigma^2}\right]^2 (\mu - \tau)^2 + \frac{n(v^2)^2\sigma^2}{(nv^2 + \sigma^2)^2} \end{aligned}$$

$$\begin{aligned}
 R_B(\mu^*) &= E\left[E\left(L(\mu, \mu^*)|\mu\right)\right] = E\left[\left[\frac{\sigma^2}{nv^2 + \sigma^2}\right]^2 (\mu - \tau)^2 + \frac{n(v^2)^2 \sigma^2}{(nv^2 + \sigma^2)^2}\right] \\
 &= \left[\frac{\sigma^2}{nv^2 + \sigma^2}\right]^2 D\mu + \frac{n(v^2)^2 \sigma^2}{(nv^2 + \sigma^2)^2} = \left[\frac{\sigma^2}{nv^2 + \sigma^2}\right]^2 v^2 + \frac{n(v^2)^2 \sigma^2}{(nv^2 + \sigma^2)^2} \\
 &= \frac{\sigma^2 v^2}{nv^2 + \sigma^2}
 \end{aligned}$$

注：若  $X \sim N(\mu, 1)$ ， $\mu \sim N(0, 1)$ ，则  $\mu$  的贝叶斯估计  $\mu^*(x_1, \dots, x_n) = \frac{n\bar{x}}{n+1} = \frac{1}{n+1} \sum_{i=1}^n x_i$ ，

贝叶斯风险  $R_B(\mu^*) = \frac{1}{n+1}$ 。

例 4 彩电寿命服从指数分布，其密度函数为

$$p(t|\theta) = \frac{1}{\theta} e^{-t/\theta}, \quad t > 0$$

其中  $\theta > 0$  是彩电的平均寿命。现从一批彩电中随机抽取  $n$  台进行寿命试验。试验到第  $r$  台失效为止，其失效时间为  $t_1 \leq t_2 \leq \cdots \leq t_r$ ，另外  $n-r$  台彩电直到试验停止时（ $t_r$ ）还未失效。这种试验称为截尾寿命试验，所得样本  $(t_1, \cdots, t_r)$  为截尾样本。试求彩电平均寿命  $\theta$  的贝叶斯估计。

解：截尾样本的联合分布为

$$\begin{aligned} p(t_1, \cdots, t_r | \theta) &= \frac{n!}{(n-r)!} \prod_{i=1}^r p(t_i | \theta) [1 - F(t_r | \theta)]^{n-r} = \frac{n!}{(n-r)!} \prod_{i=1}^r \left( \frac{1}{\theta} e^{-t_i/\theta} \right) [e^{-t_r/\theta}]^{n-r} \\ &= \frac{n!}{(n-r)!} \frac{1}{\theta^r} e^{-\frac{1}{\theta} \left( \sum_{i=1}^r t_i + (n-r)t_r \right)} \end{aligned}$$

选用倒  $\Gamma$  分布  $IGa(\alpha, \lambda)$  作为  $\theta$  的先验分布，其密度函数为

$$\pi(\theta) = \frac{\lambda^\alpha}{\Gamma(\alpha)} \theta^{-(\alpha+1)} e^{-\lambda/\theta}, \quad \theta > 0$$

其中  $\alpha > 0, \lambda > 0$  是两个待定参数，其数学期望  $E\theta = \frac{\lambda}{\alpha-1}$ 。



## $\theta$ 的后验分布

$$\begin{aligned}
 h(\theta|t_1, \dots, t_r) &= \frac{\pi(\theta)p(t_1, \dots, t_r|\theta)}{\int_0^{+\infty} \pi(\theta)p(t_1, \dots, t_r|\theta)d\theta} = \frac{\theta^{-(\alpha+1)}e^{-\lambda/\theta} \frac{1}{\theta} e^{-\frac{1}{\theta}\left(\sum_{i=1}^r t_i + (n-r)t_r\right)}}{\int_0^{+\infty} \theta^{-(\alpha+1)}e^{-\lambda/\theta} \frac{1}{\theta} e^{-\frac{1}{\theta}\left(\sum_{i=1}^r t_i + (n-r)t_r\right)}d\theta} = \frac{\theta^{-(\alpha+r+1)}e^{-\frac{1}{\theta}\left(\lambda + \sum_{i=1}^r t_i + (n-r)t_r\right)}}{\int_0^{+\infty} \theta^{-(\alpha+r+1)}e^{-\frac{1}{\theta}\left(\lambda + \sum_{i=1}^r t_i + (n-r)t_r\right)}d\theta} \\
 &= \frac{\left(\lambda + \sum_{i=1}^r t_i + (n-r)t_r\right)^{\alpha+r}}{\Gamma(\alpha+r)} \theta^{-(\alpha+r+1)} e^{-\frac{1}{\theta}\left(\lambda + \sum_{i=1}^r t_i + (n-r)t_r\right)}, \quad \theta > 0
 \end{aligned}$$

即  $\theta|t_1, \dots, t_r \sim IGa(\alpha + r, \lambda + \sum_{i=1}^r t_i + (n-r)t_r)$ ， $\theta$  的贝叶斯估计为

$$\theta^*(t_1, \dots, t_r) = E(\theta|t_1, \dots, t_r) = \frac{\lambda + \sum_{i=1}^r t_i + (n-r)t_r}{\alpha + r - 1}$$

注：若随机变量  $X \sim Ga(\alpha, \lambda)$ ，则  $\frac{1}{X}$  的分布称为倒伽玛分布，记为  $IGa(\alpha, \lambda)$ 。

# 贝叶斯估计的误差

定义 5 参数  $\theta$  的后验分布为  $h(\theta|x_1, \dots, x_n)$ ， $\theta$  的贝叶斯估计为  $\hat{\theta}$ ，则

$$MSE(\hat{\theta}|x_1, \dots, x_n) = E_{\theta|(x_1, \dots, x_n)}(\hat{\theta} - \theta)^2$$

称为  $\hat{\theta}$  的后验均方误差， $\sqrt{MSE(\hat{\theta}|x_1, \dots, x_n)}$  称为  $\hat{\theta}$  的后验标准误差。

估计量  $\hat{\theta}$  的后验均方误差越小，贝叶斯估计的误差越小。当  $\hat{\theta} = E(\theta|x_1, \dots, x_n) = \hat{\theta}_E$  时，

$$MSE(\hat{\theta}_E|x_1, \dots, x_n) = E_{\theta|(x_1, \dots, x_n)}(\hat{\theta}_E - \theta)^2 = D[\theta|(x_1, \dots, x_n)]$$

称为后验方差，称  $\sqrt{D[\theta|(x_1, \dots, x_n)]}$  为后验标准差。

$$\begin{aligned} MSE(\hat{\theta}|x_1, \dots, x_n) &= E_{\theta|(x_1, \dots, x_n)}(\hat{\theta} - \theta)^2 = E_{\theta|(x_1, \dots, x_n)}[(\hat{\theta} - \hat{\theta}_E) + (\hat{\theta}_E - \theta)]^2 \\ &= E_{\theta|(x_1, \dots, x_n)}(\hat{\theta} - \hat{\theta}_E)^2 + E_{\theta|(x_1, \dots, x_n)}(\hat{\theta}_E - \theta)^2 \\ &= (\hat{\theta} - \hat{\theta}_E)^2 + D(\theta|x_1, \dots, x_n) \end{aligned}$$

当  $\hat{\theta}_E = E(\theta|x_1, \dots, x_n)$  时，后验均方误差最小，所以实际中常常取后验均值作为  $\theta$  的贝叶斯估计值。

# 贝叶斯区间估计



定义 6 参数  $\theta$  的后验分布为  $h(\theta|x_1, \dots, x_n)$ , 对给定的样本  $(X_1, \dots, X_n)$  和概率  $1-\alpha$  ( $0 < \alpha < 1$ ),

若存在两个统计量  $\hat{\theta}_L = \hat{\theta}_L(X_1, \dots, X_n)$  和  $\hat{\theta}_U = \hat{\theta}_U(X_1, \dots, X_n)$ , 使得

$$P(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U | x_1, \dots, x_n) \geq 1 - \alpha$$

称区间  $[\hat{\theta}_L, \hat{\theta}_U]$  为参数  $\theta$  的置信度  $1-\alpha$  的贝叶斯估计区间, 简称  $\theta$  的  $1-\alpha$  置信区间。

$$P(\theta \geq \hat{\theta}_L | x_1, \dots, x_n) \geq 1 - \alpha, \quad P(\theta \leq \hat{\theta}_U | x_1, \dots, x_n) \geq 1 - \alpha$$

称  $\hat{\theta}_L, \hat{\theta}_U$  为  $\theta$  的  $1-\alpha$  (单侧) 置信下限和 (单侧) 置信上限。

寻求贝叶斯置信区间只需要  $\theta$  的后验分布

例 5 设  $(X_1, \cdots, X_n)$  是来自正态总体  $N(\mu, \sigma^2)$  的一个样本,  $\sigma^2$  已知,  $\mu$  的先验分布  $N(\tau, v^2)$ , 求  $\mu$  的  $1-\alpha$  贝叶斯置信区间。

解:  $\mu$  的后验分布:

$$\mu|(x_1, \cdots, x_n) \sim N(\mu_1, \sigma_1^2), \mu_1 = \frac{\tau\sigma^2 + nv^2\bar{x}}{nv^2 + \sigma^2}, \sigma_1^2 = \frac{v^2\sigma^2}{nv^2 + \sigma^2}, \frac{\mu|(x_1, \cdots, x_n) - \mu_1}{\sigma_1} \sim N(0, 1)$$

$$P\left(\left|\frac{\mu|(x_1, \cdots, x_n) - \mu_1}{\sigma_1}\right| \geq u_{1-\frac{\alpha}{2}}\right) = 1-\alpha, \text{ 即 } P\left(\mu_1 - \sigma_1 u_{1-\frac{\alpha}{2}} \leq \mu|(x_1, \cdots, x_n) \leq \mu_1 + \sigma_1 u_{1-\frac{\alpha}{2}}\right) = 1-\alpha$$

$\mu$  的  $1-\alpha$  贝叶斯置信区间为:  $\left[\mu_1 - \sigma_1 u_{1-\frac{\alpha}{2}}, \mu_1 + \sigma_1 u_{1-\frac{\alpha}{2}}\right]$ , 区间长度为  $2\sigma_1 u_{1-\frac{\alpha}{2}}$ 。

注: 经典估计中  $\mu$  的  $1-\alpha$  置信区间  $\left[\mu - \frac{\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}}, \mu + \frac{\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}}\right]$ , 区间长度为  $\frac{2\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}}$ ;

$$\frac{2\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}} - 2\sigma_1 u_{1-\frac{\alpha}{2}} = 2u_{1-\frac{\alpha}{2}} \left(\frac{\sigma}{\sqrt{n}} - \sigma_1\right) = \frac{2\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}} \left(1 - \sqrt{\frac{v^2}{v^2 + \sigma^2/n}}\right) > 0, \text{ 即贝叶斯区间估计}$$

的精度高于经典区间估计。



## 第8次作业:

- 孙p.62 习题二
- 50、51.





# 谢谢!



上海交通大学  
SHANGHAI JIAO TONG UNIVERSITY

